

Ich möchte die Gestenevaluation meiner Bachelorarbeit unabhängig nachvollziehen und aus den bereitgestellten Rohdaten berechnen. Ich stelle folgende Dateien bereit:

1. test_cases.csv
 - Enthält 50 englischsprachige Testfälle, ihre Kategorien und die jeweils erwarteten Gestenmengen.
2. gesture_eval_results_llama31_8b.csv
 - Enthält 150 Testläufe des Sprachmodells Llama 3.1 8B.
3. gesture_eval_results_llama31_70b.csv
 - Enthält 150 Testläufe des Sprachmodells Llama 3.1 70B.
4. run_gesture_eval.py
 - Enthält das verwendete Evaluationsverfahren und die Regeln zur Berechnung der Match-Rate und des automatischen Scores.
5. Evaluations Kapitel meiner Bachelorarbeit mit folgenden Regeln
 - Für die Evaluation wurde ein automatisiertes Testverfahren entwickelt. Die Testfälle sind in der Datei test_cases.csv gespeichert und werden durch das Skript run_gesture_eval.py ausgeführt. Die Testmenge umfasst 50 englischsprachige Nutzereingaben aus acht kommunikativen Kategorien. Jeder Testfall wurde mit beiden Sprachmodellen jeweils dreimal ausgeführt. Daraus ergeben sich 150 Testläufe pro Modell und insgesamt 300 Testläufe. Vor jedem Testlauf wird der bisherige Gesprächsverlauf gelöscht. Dadurch werden die Eingaben unabhängig voneinander verarbeitet. Bewertet werden nur die Gesten, die entsprechend der Anzahl der erzeugten Antwortsegmente tatsächlich verwendet werden. Die Evaluation berücksichtigt damit auch die Validierung der Modellausgabe und die in Abschnitt 5.5.2 beschriebene Standardgeste talk_pose.
 - Für die Bewertung werden zwei zentrale Kennzahlen verwendet: die Match-Rate und der automatische Score. Die Match-Rate zeigt, welcher Anteil der verwendeten Gesten für einen Testfall als passend festgelegt wurde:
 - $\text{Match-Rate} = (\text{Anzahl passender Gesten} / \text{Anzahl verwendeter Gesten}) * 100$
 - Werden beispielsweise drei Gesten verwendet und zwei davon als passend bewertet, beträgt die Match-Rate 66,7%. Eine Match-Rate von 100% bedeutet, dass alle verwendeten Gesten zur erwarteten Gestenmenge gehören. Die mittlere Match-Rate ist der Durchschnitt der Match-Raten aller betrachteten Testläufe. Sie zeigt, wie hoch der Anteil passender Gesten im Mittel war. Der mittlere Score ist der Durchschnitt der Scores aller betrachteten Testläufe. Je näher der Wert an 2 liegt, desto häufiger wurden überwiegend passende Gestenfolgen erzeugt. Zusätzlich wird erfasst, ob mindestens eine passende Geste enthalten ist, ob bereits die erste Geste zum Gesprächskontext passt und ob eine unangemessen starke Geste verwendet wurde.

Bitte führe folgende Schritte durch:

1. Untersuche zunächst die Struktur und die Spalten aller bereitgestellten CSV-Dateien.
2. Lies das Evaluationsskript und erkläre genau, welche Gesten eines Testlaufs ausgewertet werden. Berücksichtige insbesondere, ob nur die tatsächlich verwendeten Gesten ausgewertet werden und wie fehlende Gesten durch talk_pose ergänzt werden.

3. Rekonstruiere die Berechnung der Match-Rate eines einzelnen Testlaufs. Die Match-Rate soll dem Anteil der verwendeten Gesten entsprechen, die zur erwarteten Gestenmenge des jeweiligen Testfalls gehören.
4. Prüfe anhand des Skripts die genaue Reihenfolge der Score-Regeln. Nach dem verwendeten Verfahren gilt:
 - a. Score 0: ungültiger Gestenname oder Match-Rate unter 30 Prozent.
 - b. Score 1: Match-Rate von mindestens 30, aber unter 60 Prozent oder eine unangemessen starke Geste, sofern zuvor keine Bedingung für Score 0 erfüllt wurde.
 - c. Score 2: Match-Rate von mindestens 60 Prozent und weder eine ungültige noch eine unangemessen starke Geste.
5. Berechne für jedes Modell unabhängig:
 - a. Anzahl der Testläufe
 - b. mittlere Match-Rate
 - c. Anzahl und Anteil der Testläufe mit mindestens einer passenden Geste
 - d. Anzahl und Anteil der Testläufe mit einer passenden ersten Geste
 - e. mittleren automatischen Score
 - f. Anzahl und Anteil der Scores 0, 1 und 2
 - g. Anzahl ungültiger Gestennamen
 - h. Anzahl und Anteil unangemessen starker Gesten
6. Berechne zusätzlich für jede Testkategorie:
 - a. die mittlere Match-Rate des 8B-Modells
 - b. die mittlere Match-Rate des 70B-Modells
 - c. den Anteil passender erster Gesten beim 8B-Modell
 - d. den Anteil passender erster Gesten beim 70B-Modell
7. Die mittlere Match-Rate soll als arithmetisches Mittel der Match-Raten aller einzelnen Testläufe berechnet werden. Jeder Testlauf soll dabei unabhängig von seiner Anzahl an Antwortsegmenten dasselbe Gewicht besitzen.
8. Zeige die verwendeten Formeln und mindestens ein konkretes Berechnungsbeispiel für:
 - a. eine Match-Rate
 - b. einen Score
 - c. den mittleren Score eines Modells
9. Erstelle anschließend zwei übersichtliche Tabellen:
 - a. Gesamtergebnisse beider Modelle
 - b. Ergebnisse nach Testkategorie
10. Vergleiche die unabhängig berechneten Werte erst am Ende mit den Angaben im bereitgestellten Evaluationskapitel. Weise auf jede Abweichung hin.
11. Wichtig:
 - a. Verwende nur die bereitgestellten Dateien
 - b. Übernimm die veröffentlichten Werte nicht ungeprüft.
 - c. Erfinde keine fehlenden Daten.
 - d. Verändere oder bereinige die Rohdaten nicht unbemerkt.
 - e. Weise ausdrücklich darauf hin, falls Spalten, Testfälle oder Regeln mehrdeutig sind.
 - f. Unterscheide klar zwischen Ergebnissen, die direkt aus den Daten berechnet wurden, und Interpretationen der Ergebnisse.